

請實做以下兩種不同feature的模型，回答第(1)~(2)題：

(1) 抽全部9小時內的污染源feature當作一次項(加bias)

(2) 抽全部9小時內pm2.5的一次項當作feature(加bias)

備註：

a. NR請皆設為0，其他的非數值(特殊字元)可以自己判斷

b. 所有 advanced 的 gradient descent 技術(如: adam, adagrad 等) 都是可以用的

c. 第1-2題請都以題目給訂的兩種model來回答

d. 同學可以把model訓練好，kaggle死線之後便可以無限上傳。

e. 根據助教時間的公式表示，(1) 代表 $p = 9 \times 18 + 1$ 而(2) 代表 $p = 9 * 1 + 1$

1. (1%) 記錄誤差值 (RMSE)(根據kaggle public+private分數)，討論兩種feature的影響

ANS：

model1 的 RMSE = (4.79129, 4.88643)；model2 的 RMSE = (4.88643, 5.17965)。如果用所有的feature下去做迴歸，我們會有135個regressor加上一個bias，然而我們發現比model2只有用9個regressor加上一個bias的還要好，在直覺上是合理的，因為pm2.5應該會受其他環境變量影響，而非單只受到過去時間的pm2.5影響而已。

2. (1%) 解釋什麼樣的data preprocessing 可以improve你的training/testing accuracy，ex. 你怎麼挑掉你覺得不適合的data points。請提供數據(RMSE)以佐證你的想法。

ANS：

針對數據我將“-”的值補上，此欄位的前一個值進行補值，而出現一些亂碼或是數字突然>700的資料筆數直接刪除。接著我在第一題的兩個model中，都刪除training data中pm2.5大於50的資料，主要原因是我發現testing set中的pm2.5大多都落在0~50的範圍內，只有少數幾筆大於50。若完全沒有做資料修剪得到的結果是model1的RMSE = (4.84498, 5.25181)；model2的RMSE = (4.91346, 5.06973)，可以發現都比有做修剪資料得來的差。

3.(3%) Refer to math problem

NO:

DATE: / /

(i.b)

We change the parameter of w .

$$\text{Define } \left\{ \begin{array}{l} w = \begin{pmatrix} b \\ w \end{pmatrix}_{k+1} \Rightarrow L_{\text{ssq}}(w) = \frac{1}{2N} \sum_{i=1}^N (y_i - x_i^T w)^2. \end{array} \right.$$

$$x_i = \begin{pmatrix} 1 \\ x_i \end{pmatrix}_{k+1}, \quad y = \begin{pmatrix} y_1 \\ \vdots \\ y_N \end{pmatrix}$$

$X = (X_1, \dots, X_N)_{(k+1) \times N}$ be a matrix. Then we can

$$\text{rewrite } L_{\text{ssq}}(w) = \frac{1}{2N} (Y - X^T w)^T (Y - X^T w).$$

$$\frac{\partial L_{\text{ssq}}}{\partial w} = \frac{1}{2N} [-2XY + 2(XX^T)w].$$

$$\frac{\partial L_{\text{ssq}}}{\partial w} \Big|_{\hat{w}} = 0 \Rightarrow 2(XX^T)\hat{w} = 2XY.$$

$$\Rightarrow \hat{w} = (XX^T)^{-1}XY = \begin{pmatrix} b \\ \hat{w} \end{pmatrix} \#.$$

NO:

DATE: / /

1.(c) :-

$$\frac{\partial L_{\text{reg}}}{\partial w} = \frac{1}{N} \sum_{i=1}^N (y_i - x_i^T w - b)^2 + \lambda \|w\|^2$$

$$= \frac{-1}{2N} 2 \sum_{i=1}^N x_i (y_i - x_i^T w - b) + \lambda w = 0.$$

$$\Rightarrow \left[\sum_{i=1}^N x_i x_i^T + \lambda I_N \right] w + b \sum_{i=1}^N x_i = \sum_{i=1}^N x_i y_i \quad \text{--- ①}$$

$$\frac{\partial L_{\text{reg}}}{\partial b} = \frac{-1}{2N} 2 \sum_{i=1}^N (y_i - x_i^T w - b) = 0.$$

$$\Rightarrow \sum_{i=1}^N x_i^T w + \lambda b = \sum_{i=1}^N x_i \quad \text{--- ②}$$

① + ②

$$\begin{pmatrix} \sum_{i=1}^N x_i x_i^T + \lambda I_N & \sum_{i=1}^N x_i \\ \sum_{i=1}^N x_i^T & N \end{pmatrix} \begin{pmatrix} \hat{w} \\ \hat{b} \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^N x_i y_i \\ \sum_{i=1}^N y_i \end{pmatrix}$$

$$\Rightarrow \begin{pmatrix} \hat{w} \\ \hat{b} \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^N x_i x_i^T + \lambda I_N & \sum_{i=1}^N x_i \\ \sum_{i=1}^N x_i^T & N \end{pmatrix}^{-1} \begin{pmatrix} \sum_{i=1}^N x_i y_i \\ \sum_{i=1}^N y_i \end{pmatrix} \#$$

(a).

This is the simple linear regression.

So,

$$\hat{w} = \frac{\sum xy}{\sum x^2}$$

$$\hat{b} = \bar{y} - \hat{w} \bar{x}$$

$$\hat{w} = \frac{\sum_{i=1}^5 (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^5 (x_i - \bar{x})^2} = \frac{10.5}{10} = 1.05 \text{ #.}$$

$$\hat{b} = 3.36 - 1.05 \cdot 3 = 0.21 \text{ #}$$

2.

$$E\left(\frac{1}{N} \sum_{i=1}^N \left(f_{w,b}(x_i + y_i) - y_i\right)^2\right)$$

$$= \frac{1}{N} \sum_{i=1}^N E\left(W^T(x_i + y_i) + b - y_i\right)^2 = \frac{1}{N} \sum_{i=1}^N E\left((W^T x_i + b - y_i) + W^T y_i\right)^2$$

$$= \frac{1}{N} \sum_{i=1}^N \left[E\left(f_{w,b}(x_i) - y_i\right)^2 + E\left(W^T y_i\right)^2 + 2(f_{w,b}(x_i) - y_i) \underbrace{E(W^T y_i)}_0 \right]$$

$$= \frac{1}{N} \sum_{i=1}^N \left(f_{w,b}(x_i) - y_i\right)^2 + \underbrace{\frac{1}{N} \sum_{i=1}^N \text{Var}(W^T y_i)}_0$$

$$W^T \text{Var}(y_i) W = \|W\|^2 \sigma^2$$

$$= \frac{1}{N} \sum_{i=1}^N \left(f_{w,b}(x_i) - y_i\right)^2 + \frac{\sigma^2}{2} \|W\|^2 \#.$$

3.

(a).

$$e_0 = \frac{1}{N} \sum_{i=1}^N g_k(x_i)$$

$$e_k = \frac{1}{N} \sum_{i=1}^N g_k(x_i) + \frac{1}{N} \sum_{i=1}^N y_i - 2 \frac{1}{N} \sum_{i=1}^N g_k(x_i) y_i$$

$$= s_k + e_0 - \frac{2}{N} \sum_{i=1}^N g_k(x_i) y_i$$

$$\Rightarrow \sum_{i=1}^N g_k(x_i) y_i = \frac{N}{2} (s_k + e_0 - e_k) \quad \forall k = 1, \dots, K+1. \quad \#.$$

(b).

$$\frac{\partial}{\partial \alpha_k} \left. \frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K (\alpha_k g_k(x_i) - y_i)^2 \right|_{\alpha_k = \hat{\alpha}_k} = 0.$$

$$\frac{1}{N} \sum_{i=1}^N (\hat{\alpha}_k g_k(x_i) - y_i) g_k(x_i) = 0.$$

$$\hat{\alpha}_k \sum_{i=1}^N g_k(x_i) = \sum_{i=1}^N y_i g_k(x_i) \Rightarrow \hat{\alpha}_k = \frac{\sum_{i=1}^N y_i g_k(x_i)}{\sum_{i=1}^N g_k(x_i)} \quad \forall k = 1, \dots, K$$